

水下 AUV 追逃分层强化学习的 MDP 建模

1 2 维 MDP 建模

1.1 底层 MDP：二维定点轨迹规划任务

1.1.1 任务描述与 MDP 概述

二维底层任务将 AUV 限制在固定深度 $z = z_{\text{fix}}$ 的水平面内运动，消除了垂荡、横滚和纵倾自由度。智能体需从当前位置驶向随机采样的静态目标 $\mathbf{p}_g = (x_g, y_g)^\top$ 。该任务建模为有限时域 MDP $\mathcal{M}^{\text{low}, 2\text{D}} = \langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma, H \rangle$ ，各要素定义如下。

1. **状态空间** $\mathcal{S} \subset \mathbb{R}^8$ ：由体坐标系下的相对位置误差、航向偏差、速度分量和距离构成的 8 维连续状态。二维约束下 AUV 的有效物理自由度为 3 维位姿 (x, y, ψ) 和 3 维速度 (u, v, r) ，加上 2 维目标位置共 8 维。经坐标变换后维度不变。
2. **动作空间** $\mathcal{A} = [-1, 1]^3$ ：3 维连续动作，对应水平面运动群 $SE(2)$ 的 2 个平移自由度（沿纵轴前后、沿横轴左右）和 1 个旋转自由度（绕竖轴转向）。
3. **状态转移** $\mathcal{P} : \mathcal{S} \times \mathcal{A} \rightarrow \mathcal{S}$ ：由 Fossen 非线性动力学方程 (??)（施加二维约束后）的数值积分决定，动作经双环控制器（外环 PD 速度控制 + 内环 PID 姿态控制）转换为推进器推力后驱动积分。不确定性来源包括海流外部扰动以及非线性动力学对微小状态差异的敏感放大效应。
4. **奖励函数** $\mathcal{R} : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ ：由位置惩罚、距离改善、航向对齐、前进方向、接近奖励、目标到达（稀疏）、时间惩罚和自旋惩罚共 8 个分量组成，引导智能体学会“先对准、再前进、精确到达”的行为模式。大额稀疏目标奖励确保到达目标始终是最优选择。
5. **折扣因子与时域**： $\gamma \in (0, 1)$ 为折扣因子， $H = \lfloor T_{\text{max}}^{\text{low}} / \Delta t \rfloor$ 为最大步数。

回合开始时 AUV 置于初始位姿，目标在附近随机采样。每步 k ，智能体观测 $\mathbf{s}_k$ ，选择动作 $\mathbf{a}_k$ ，环境根据转移核 $\mathcal{P}$ 返回新状态 $\mathbf{s}_{k+1}$ 和标量奖励 $r_k = \mathcal{R}(\mathbf{s}_k, \mathbf{a}_k)$ ，直至回合终止。

下面逐一详细推导各要素。

1.1.2 状态空间 $\mathcal{S}^{\text{low},2\text{D}}$

在二维约束下，AUV 的运动自由度为水平面内的平移和绕竖轴的旋转，有效物理状态为

$$\mathbf{s}_k^{\text{phys}} = \left[\underbrace{x_k, y_k, \psi_k}_{\text{3维位姿}}, \underbrace{u_k, v_k, r_k}_{\text{3维速度}}, \underbrace{x_g, y_g}_{\text{2维目标}} \right]^\top \in \mathbb{R}^8. \quad (1)$$

为使策略对绝对位置和绝对航向具有不变性，我们对物理状态进行坐标变换，得到等维度的 MDP 状态向量：

$$\mathbf{s}_k = [e_x^b, e_y^b, \delta\psi, \alpha_g, u_k, v_k, r_k, d_k]^\top \in \mathbb{R}^8. \quad (2)$$

这是一个 $\mathbb{R}^8 \rightarrow \mathbb{R}^8$ 的坐标变换（非降维），变换后的状态对平面刚体运动群 $SE(2)$ 的平移和旋转具有不变性。

1.1.3 动作空间 $\mathcal{A}^{\text{low},2\text{D}}$

二维水平面内的运动具有 3 个自由度：沿纵轴的平移（前后）、沿横轴的平移（左右）和绕竖轴的旋转（转向），对应平面运动群 $SE(2)$ 的全部自由度。动作为 3 维连续向量：

$$\mathbf{a}_k = [a_k^{\text{surge}}, a_k^{\text{sway}}, a_k^{\text{yaw}}]^\top \in [-1, 1]^3, \quad (3)$$

各分量映射到物理指令：

- a_k^{surge} ：沿 AUV 自身纵轴的前后位移指令，映射为 $\Delta x_{\text{cmd}}^b = a_k^{\text{surge}} \ell_{\text{surge}}$ （ ℓ_{surge} 为纵荡步长参数）；
- a_k^{sway} ：沿 AUV 自身横轴的左右位移指令，映射为 $\Delta y_{\text{cmd}}^b = a_k^{\text{sway}} \ell_{\text{sway}}$ ；
- a_k^{yaw} ：绕竖轴的航向增量指令，映射为 $\Delta\psi_{\text{cmd}} = a_k^{\text{yaw}} \delta\psi_{\text{max}}$ 。

需要强调的是，前两个分量控制的是体坐标系下的平移（而非地球系下的 X, Y 方向），第三个分量控制旋转，因此虽然是二维空间任务，动作维度为 3。

1.1.4 状态转移 $\mathcal{P}^{\text{low},2\text{D}}$

给定状态 $\mathbf{s}_k$ 和动作 $\mathbf{a}_k$ ，转移过程为三步：

1. 将 $\mathbf{a}_k$ 经双环控制器 ((?)-(?)) 转换为推力；
2. 代入 Fossen 方程 (??)，使用数值积分器推进 Δt ；
3. 强制二维约束： $z_{k+1} = z_{\text{fix}}$ ， $\phi_{k+1} = \theta_{k+1} = 0$ ， $w_{k+1} = p_{k+1} = q_{k+1} = 0$ 。

若启用随机海流模型，则同时推进扰动状态。形式化地，

$$\mathbf{s}_{k+1} \sim \mathcal{P}^{\text{low},2\text{D}}(\cdot \mid \mathbf{s}_k, \mathbf{a}_k). \quad (4)$$

不确定性来源包括海流外部扰动以及非线性动力学对微小状态差异的敏感放大效应。后者在传统意义上属于确定性系统，但从 RL 智能体的角度看表现为一种“有效不确定性”，正是强化学习相比经典线性化控制方法的优势所在。

1.1.5 奖励函数 $\mathcal{R}^{\text{low},2\text{D}}$

第 k 步奖励由 8 个分量组成：

$$r_k = r_k^{\text{pos}} + r_k^{\text{imp}} + r_k^{\text{head}} + r_k^{\text{dir}} + r_k^{\text{prox}} + r_k^{\text{goal}} + r_k^{\text{time}} + r_k^{\text{spin}}. \quad (5)$$

(i) 位置惩罚。 对距离施加线性惩罚，提供全局梯度信号：

$$r_k^{\text{pos}} = -w_{\text{pos}} d_k. \quad (6)$$

(ii) 距离改善奖励。 鼓励逐步缩短到目标的距离，对运动趋势提供直接反馈：

$$r_k^{\text{imp}} = w_{\text{imp}} (d_{k-1} - d_k). \quad (7)$$

(iii) 航向对齐奖励。 鼓励 AUV 艏向对准目标方位：

$$r_k^{\text{head}} = w_{\text{head}} \left(1 - \frac{|\delta_\psi|}{\pi}\right). \quad (8)$$

(iv) 前进方向奖励。 当航向基本正确且具有正向速度时给予奖励，鼓励“先对准、再前进”：

$$r_k^{\text{dir}} = \begin{cases} w_{\text{dir}} u_k, & \text{若 } d_k > d_{\text{dir}}, |\delta_\psi| < \delta_{\text{dir}}, u_k > 0, \\ 0, & \text{其他情况,} \end{cases} \quad (9)$$

d_{dir} 为触发距离阈值（极近处不触发以防过冲）， δ_{dir} 为航向偏差阈值。

(v) 接近奖励。 在目标附近给予额外的密集塑形奖励：

$$r_k^{\text{prox}} = \begin{cases} w_{\text{prox}} (d_{\text{prox}} - d_k), & d_k < d_{\text{prox}}, \\ 0, & \text{其他情况。} \end{cases} \quad (10)$$

(vi) 目标到达奖励（稀疏）。 成功到达时给予大额一次性奖励：

$$r_k^{\text{goal}} = \begin{cases} R_{\text{goal}}, & d_k < d_{\text{succ}}, \\ 0, & \text{其他情况。} \end{cases} \quad (11)$$

(vii) 时间惩罚与自旋惩罚。 时间惩罚鼓励快速到达： $r_k^{\text{time}} = -c_{\text{time}}$ 。自旋惩罚抑制原地旋转而不前进的退化行为（水下旋转阻尼小，策略易陷入此局部最优）：

$$r_k^{\text{spin}} = \begin{cases} -w_{\text{spin}} |r_k|, & |r_k| > r_{\text{thresh}} \text{ 且 } |u_k| < u_{\text{thresh}}, \\ 0, & \text{其他情况。} \end{cases} \quad (12)$$

奖励设计思路。 R_{goal} 远大于单步密集奖励之和，确保到达目标始终是最优选择。距离改善项 r^{imp} 提供最强的逐步引导信号，航向对齐与方向奖励构成辅助引导。

1.1.6 终止条件与优化目标

回合在以下情况终止：

1. 成功 (terminated): $d_k < d_{\text{succ}}$;
2. 越界 (terminated): $|x_k|$ 或 $|y_k| > L_{\text{bound}}$;
3. 超时 (truncated): $k \geq H^{\text{low}}$ 。

问题的自然目标。 底层定点到达任务的本质是一个约束最小时间到达问题。设 T_{goal} 为 AUV 首次满足 $d_k < d_{\text{succ}}$ 的时刻（若未到达则 $T_{\text{goal}} = +\infty$ ），自然目标为

$$\min_{\pi^{\text{low},2\text{D}}} \mathbb{E}_{\pi^{\text{low},2\text{D}}} [T_{\text{goal}}] \quad \text{s.t.} \quad \begin{cases} M\dot{\nu} + C(\nu)\nu + D(\nu)\nu + g(\eta) = \tau_{\text{thrust}} + \tau_{\text{ext}}, \\ \mathbf{s}_k \in \mathcal{S}_{\text{safe}}, \quad \forall k \leq T_{\text{goal}}. \end{cases} \quad (13)$$

其中 $\mathcal{S}_{\text{safe}}$ 为安全状态集（不越界、姿态在可控范围内等）。或者说，在所有能以某种方式到达目标的策略中，我们希望找到一个使期望到达时间最短的策略。

RL 优化目标。 综合以上分析，底层强化学习的优化目标为

$$\pi^{\text{low},2\text{D},*} = \arg \max_{\pi^{\text{low},2\text{D}}} \mathbb{E}_{\pi^{\text{low},2\text{D}}} \left[\sum_{k=0}^{H^{\text{low}}} (\gamma^{\text{low}})^k r_k \right], \quad (14)$$

其中 r_k 由公式 (5) 定义。在 $R_{\text{goal}} \gg H^{\text{low}} \cdot \max_k |r_k^{\text{dense}}|$ 的条件下，公式 (14) 的最优策略与原始约束最小时间问题 (13) 在以下意义上等价——任何使 (14) 取得更高期望回报的策略，必然具有更高的到达概率和更短的期望到达时间。最终策略的性能通过目标到达成功率 $\eta_{\text{succ}} = N_{\text{succ}}/N_{\text{total}}$ 来评估。

1.2 高层 MDP：二维追逃任务

1.2.1 任务描述与 MDP 概述

在二维高层任务中，AUV 作为追击者 (pursuer)，在水平面内追捕一个移动的逃逸者 (evader)。两者具有如下不对称动力学特性：

- **最大速度**：逃逸者优于追击者， $v_{\max}^e > v_{\max}^p$ ，逃逸者全速直线逃跑时追击者无法尾追；
- **最大加速度**：追击者优于逃逸者， $a_{\max}^p > a_{\max}^e$ ，追击者能更快地改变速度方向 and 大小。

加速度优势为追击者提供三种战术机会：(1) 截击——快速转向切入逃逸者预测航线；(2) 迫使转弯——逃逸者转弯时因加速度小而减速，追击者趁机拉近距离；(3) 地形利用——凭借全局地形知识将逃逸者驱赶向受限区域，压缩其机动空间。

追击者对逃逸者状态和地形具有全局可观测能力。高层问题建模为 MDP $\mathcal{M}^{\text{high},2\text{D}} = \langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma, H \rangle$ ，各要素定义如下。

1. **状态空间** $\mathcal{S} \subset \mathbb{R}^{14+n_t}$ ：由追击者自身状态（5 维）、逃逸者状态（4 维）、相对几何量（5 维）和地形观测（ n_t 维）四部分拼接而成，构成完全可观测的全局态势信息。
2. **动作空间** $\mathcal{A} = [-1, 1]^2$ ：2 维连续动作，表示相对于追击者当前位置的子目标航点位移。该航点被传递给预训练好的底层策略作为执行目标。追逃、截击、包抄、地形利用等所有高层战术都编码在子目标的时空序列中。
3. **状态转移** $\mathcal{P} : \mathcal{S} \times \mathcal{A} \rightarrow \mathcal{S}$ ：每个高层动作触发底层策略执行 K 个底层时间步（或直到到达子目标），期间逃逸者同时执行其逃逸策略。高层转移核隐含了 AUV 动力学、底层策略和逃逸者动力学三者的综合效果。
4. **奖励函数** $\mathcal{R} : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ ：由捕获奖励（稀疏）、接近奖励、截击几何奖励、地形利用奖励、能量惩罚和时间惩罚共 6 个分量组成。截击几何奖励是核心——引导追击者朝逃逸者的预测位置运动，利用加速度优势弥补速度劣势。
5. **折扣因子与时域**： $\gamma \in (0, 1)$ ， $H = N_{\max}$ 为最大高层步数。

1.2.2 状态空间 $\mathcal{S}^{\text{high},2\text{D}}$

在每个高层决策步 n （宏步），追击者观测由四部分组成的状态向量：

$$\mathbf{s}_n^{\text{high}} = [\mathbf{s}_n^p, \mathbf{s}_n^e, \mathbf{s}_n^{\text{rel}}, \mathbf{s}_n^{\text{terrain}}]^\top. \quad (15)$$

追击者自身状态 $\mathbf{s}_n^p \in \mathbb{R}^5$ 。

$$\mathbf{s}_n^p = [x_n^p, y_n^p, \psi_n^p, u_n^p, v_n^p]^\top, \quad (16)$$

包含追击者的水平位置、艏向角和水平速度分量。

逃逸者状态 $\mathbf{s}_n^e \in \mathbb{R}^4$ 。

$$\mathbf{s}_n^e = [x_n^e, y_n^e, \psi_n^e, v_n^e]^\top, \quad (17)$$

其中 $v_n^e = \|\mathbf{v}_n^e\|$ 为逃逸者标量速度。知道逃逸者的航向和速度使追击者能够预判其未来走势——这对截击策略的设计至关重要。

相对几何量 $\mathbf{s}_n^{\text{rel}} \in \mathbb{R}^5$ 。

$$\mathbf{s}_n^{\text{rel}} = [d_n^{pe}, \alpha_n^{pe}, \beta_n^{pe}, v_{\text{close},n}^{pe}, \Delta\psi_n]^\top. \quad (18)$$

各分量含义：

- $d_n^{pe} = \|\mathbf{p}_n^e - \mathbf{p}_n^p\|$ ：两体间距离；
- $\alpha_n^{pe} = \text{atan2}(y_n^e - y_n^p, x_n^e - x_n^p)$ ：视线方位角（Line-of-Sight, LOS），描述”逃逸者在追击者的哪个方向”，仅依赖两者的相对位置，与速度无关；
- $\beta_n^{pe} = \arccos \frac{\mathbf{v}_n^e \cdot \mathbf{d}_n^{pe}}{\|\mathbf{v}_n^e\| \|\mathbf{d}_n^{pe}\|}$ ：目标方位角（aspect angle），描述”逃逸者在往哪个方向逃跑”—— $\beta \approx 0$ 时逃逸者朝追击者运动（迎面态势）， $\beta \approx \pi$ 时正在远离（尾追态势），此角度取决于逃逸者的速度方向与视线方向的关系；
- $v_{\text{close},n}^{pe}$ ：追击者朝逃逸者的接近速度，为追击者速度在视线方向上的投影；
- $\Delta\psi_n = \text{atan2}(\sin(\alpha_n^{pe} - \psi_n^p), \cos(\alpha_n^{pe} - \psi_n^p))$ ：追击者航向与视线方向的偏差角。

视线方位角 α^{pe} 和目标方位角 β^{pe} 的本质区别在于：前者从追击者视角回答”目标在哪”，后者从逃逸者视角回答”目标往哪跑”——两者结合才构成完整的态势判断。

地形观测 $\mathbf{s}_n^{\text{terrain}} \in \mathbb{R}^{n_t}$ 。对局部海底地形的紧凑编码（如沿若干射线方向到最近障碍物的距离）。

高层状态总维度为 $5 + 4 + 5 + n_t = 14 + n_t$ ，满足完全可观测性和马尔可夫性质。

1.2.3 动作空间 $\mathcal{A}^{\text{high},2D}$

高层策略输出子目标航点的相对位移：

$$\mathbf{a}_n^{\text{high}} = [\Delta x_n^g, \Delta y_n^g]^\top \in [-1, 1]^2. \quad (19)$$

实际航点为

$$\mathbf{p}_n^g = \mathbf{p}_n^p + \ell_{\text{high}} \mathbf{a}_n^{\text{high}}, \quad (20)$$

其中 ℓ_{high} 为缩放参数。高层动作不是推力或速度指令，而是空间子目标——高层决策”去哪里”（追逃策略层面），底层决策”怎么去”（运动控制层面）。 $\mathbf{p}_n^g$ 不是最终目的地，而是短期方向性指令；每隔 K 个底层步高层会重新决策一个新的子目标，追击者的实际轨迹由一连串不断更新的子目标串联而成。截击、包抄、利用地形等所有高层战术都编码在这一子目标序列中。

1.2.4 状态转移 $\mathcal{P}^{\text{high},2\text{D}}$

高层决策周期为 T_{macro} 。在高层步 n ，航点 $\mathbf{p}_n^g$ 被设定后，底层策略 π^{low} 执行 K 个底层步（或直到到达航点，以先发生者为准）。设 $k_0(n)$ 为高层步 n 开始时的底层时间索引，则

$$\mathbf{s}_{k_0(n)+j+1}^{\text{low}} \sim \mathcal{P}^{\text{low}}(\cdot \mid \mathbf{s}_{k_0(n)+j}^{\text{low}}, \pi^{\text{low}}(\mathbf{s}_{k_0(n)+j}^{\text{low}}; \mathbf{p}_n^g)), j = 0, \dots, K-1. \quad (21)$$

期间逃逸者同时执行其逃逸策略。高层下一状态由 K 步后的系统状态提取：

$$\mathbf{s}_{n+1}^{\text{high}} \sim \mathcal{P}^{\text{high},2\text{D}}(\cdot \mid \mathbf{s}_n^{\text{high}}, \mathbf{a}_n^{\text{high}}). \quad (22)$$

从结构上看这是一个半马尔可夫过程（宏步持续时间可变），但从高层策略视角每个宏步等价于标准 MDP 中的单步转移。

1.2.5 奖励函数 $\mathcal{R}^{\text{high},2\text{D}}$

宏步 n 的奖励为 6 个分量之和：

$$r_n^{\text{high}} = r_n^{\text{capture}} + r_n^{\text{close}} + r_n^{\text{intercept}} + r_n^{\text{terrain}} + r_n^{\text{energy}} + r_n^{\text{time,h}}. \quad (23)$$

(i) 捕获奖励（稀疏）。

$$r_n^{\text{capture}} = \begin{cases} R_{\text{win}}, & d_n^{pe} < D_c, \\ -R_{\text{lose}}, & n = N_{\text{max}} \text{ 且 } d_n^{pe} \geq D_c, \\ 0, & \text{其他情况}, \end{cases} \quad (24)$$

其中 D_c 为捕获半径， $R_{\text{win}}, R_{\text{lose}}$ 为大额稀疏奖惩。

(ii) 接近奖励。 鼓励追击者缩短与逃逸者的距离：

$$r_n^{\text{close}} = w_{\text{close}} (d_{n-1}^{pe} - d_n^{pe}). \quad (25)$$

(iii) 截击几何奖励。 由于逃逸者最大速度更高，尾追策略在其全速直线逃跑时必然失败。追击者应利用加速度优势快速转向，切入逃逸者的预测航线。逃逸者加速度小，短期内航线变化有限，线性预测可靠性高。定义预测位置 $\hat{\mathbf{p}}_{n+\tau}^e = \mathbf{p}_n^e + \tau \mathbf{v}_n^e$ ，截击奖励为

$$r_n^{\text{intercept}} = -w_{\text{int}} \min_{\tau \in [0, \tau_{\text{max}}]} \|\mathbf{p}_{n+1}^p - \hat{\mathbf{p}}_{n+\tau}^e\|. \quad (26)$$

在逃逸者未来 τ_{max} 时间内可能经过的所有位置中，找到追击者距离最近的点来衡量截击态势优劣。

(iv) 地形利用奖励。 鼓励将逃逸者驱赶向限制其逃逸路线的地形特征：

$$r_n^{\text{terrain}} = w_{\text{terrain}} (d_n^{e,\text{obs}} - d_{n-1}^{e,\text{obs}}), \quad (27)$$

$d_n^{e,\text{obs}}$ 为逃逸者到最近障碍物的距离，减小时获正奖励。地形利用与加速度优势协同：逃逸者被逼近地形后频繁转弯，每次转弯因加速度劣势而减速，为追击者创造拉近距离的窗口。

(v) 能量惩罚与时间惩罚。

$$r_n^{\text{energy}} = -w_E \|\mathbf{a}_n^{\text{high}} - \mathbf{a}_{n-1}^{\text{high}}\|^2, \quad r_n^{\text{time,h}} = -c_{\text{time}}^h. \quad (28)$$

能量惩罚抑制频繁剧烈的航点切换，时间惩罚鼓励尽快捕获。

1.2.6 终止条件与优化目标

终止条件：

1. 捕获成功 (terminated): $d_n^{pe} < D_c$;
2. 逃逸成功 (terminated): $d_n^{pe} > D_{\text{escape}}$;
3. 超时 (truncated): $n \geq N_{\text{max}}$ 。

问题的自然目标。 高层追逃问题的本质是一个非对称微分博弈。在速度劣势 ($v_{\text{max}}^e > v_{\text{max}}^p$) 但加速度优势 ($a_{\text{max}}^p > a_{\text{max}}^e$) 的约束下，设 T_{cap} 为首次满足 $d_n^{pe} < D_c$ 的宏步时刻，追击者的自然目标为 最大化有限时域内的捕获概率，并在捕获发生时最小化捕获时间：

$$\max_{\pi^{\text{high},2\text{D}}} \mathbb{P}_{\pi^{\text{high},2\text{D}}, \pi^{\text{evader}}} [T_{\text{cap}} \leq N_{\text{max}}], \quad \min_{\pi^{\text{high},2\text{D}}} \mathbb{E}[T_{\text{cap}} \mid T_{\text{cap}} \leq N_{\text{max}}]. \quad (29)$$

RL 优化目标。

$$\pi^{\text{high},2\text{D},*} = \arg \max_{\pi^{\text{high},2\text{D}}} \mathbb{E}_{\pi^{\text{high},2\text{D}}} \left[\sum_{n=0}^{N_{\text{max}}} (\gamma^{\text{high}})^n r_n^{\text{high}} \right], \quad (30)$$

其中 r_n^{high} 由公式 (23) 定义。策略性能通过捕获成功率 $\eta_{\text{cap}} = N_{\text{cap}}/N_{\text{total}}$ 评估。